



# AI Community

## 6. Понижение размерности



# План на сегодня

## 1. Понижение размерности

- a. Определение
- b. Применение
- c. Подходы

## 2. PCA

- a. Постановка задачи
- b. Решение

## 3. t-SNE

- a. Многомерное шкалирование
- b. SNE
- c. t - SNE


Понижение  
размерности

# Понижение размерности



## Понижение размерности


представляет собой преобразование данных из пространства большой размерности в пространство низкой размерности, так что представление низкой размерности сохраняет некоторые значимые свойства исходных данных.





# Зачем нужно понижать размерность?

- Необработанные данные часто являются разреженными
- Облегчает визуализацию и анализ данных
- Пространство, необходимое для хранения данных, уменьшается по мере уменьшения числа измерений
- Меньшие размеры приводят к уменьшению времени для вычислений/обучения

# Почему просто не отобрать признаки?

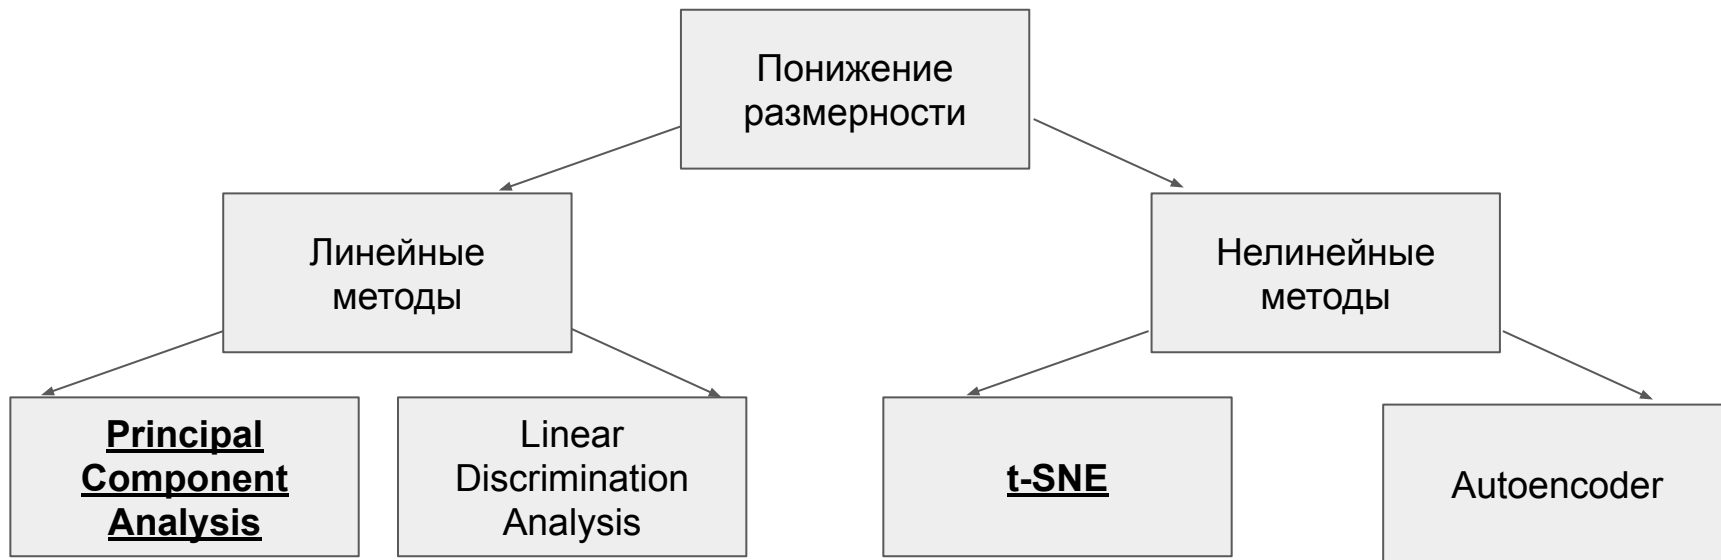









# Некоторые подходы понижения размерности



# Principal Component Analysis (PCA)

# Постановка задачи

- Исходные признаки:  $x_{ij}, D$
- Новые признаки:  $z_{ij}, d$
- Линейный подход



# Матричный вид

$$z_{ij} = \sum_{k=1}^D w_{jk} x_{ik} = \sum_{k=1}^D x_{ik} w_{kj}^T \longrightarrow Z = XW^T$$

Чтобы у этого уравнения существовало единственное решение, необходимо:


$$W^T W = I$$

, тогда

$$X = ZW$$

Задача:  $\|X - ZW\|^2 \rightarrow \min_{Z, W}$

# Решение



# Максимизация дисперсии

$$\begin{cases} \sum_{j=1}^d \mathbf{w}_j^T X^T X \mathbf{w}_j \rightarrow \max_{\mathbf{W}} \\ \mathbf{W}^T \mathbf{W} = \mathbf{I} \end{cases}$$

# Максимизация дисперсии

$$\begin{cases} \mathbf{w}_1^T \mathbf{X}^T \mathbf{X} \mathbf{w}_1 \rightarrow \max_{\mathbf{w}_1} \\ \mathbf{w}_1^T \mathbf{w}_1 = I \end{cases}$$

# Максимизация дисперсии

$$\begin{cases} \mathbf{w}_1^T \mathbf{X}^T \mathbf{X} \mathbf{w}_1 \rightarrow \max_{\mathbf{w}_1} \\ \mathbf{w}_1^T \mathbf{w}_1 = I \end{cases}$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w}_1 = \lambda \mathbf{w}_1$$




# Максимизация дисперсии

$$\begin{cases} \mathbf{w}_1^T \mathbf{X}^T \mathbf{X} \mathbf{w}_1 \rightarrow \max_{\mathbf{w}_1} \\ \mathbf{w}_1^T \mathbf{w}_1 = I \end{cases}$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w}_1 = \lambda \mathbf{w}_1$$

$$\mathbf{w}_1^T \mathbf{X}^T \mathbf{X} \mathbf{w}_1 = \lambda$$

# Решение



# Сингулярное разложение

›  $X = UDV^T$

› Столбцы  $U$  — собственные векторы  $XX^T$

› Столбцы  $V$  — собственные векторы  $X^TX$

› Диагональ  $D$  — ненулевые собственные значения  $XX^T$  и  $X^TX$  (сингулярные числа)

# Сингулярное разложение

- Найти сингулярное разложение матрицы  $X$
- Сформировать матрицу весов  $W$  из собственных векторов
- Преобразование признаков  $Z = XW$

# t-distributed Stochastic Neighbor Embedding (t-SNE)

# Многомерное шкалирование

$$\sum_{i < j}^{\ell} (\|\tilde{x}_i - \tilde{x}_j\| - d_{ij})^2 \rightarrow \min_{\tilde{x}_1, \dots, \tilde{x}_\ell}$$

# SNE

Если

$$\rho(x_i, x_j) = \alpha \rho(x_i, x_k)$$

, то

$$\rho(\tilde{x}_i, \tilde{x}_j) = \alpha \rho(\tilde{x}_i, \tilde{x}_k)$$

# t-SNE

Если

$$\rho(x_i, x_j) = \alpha \rho(x_i, x_k)$$


, то

$$\rho(\tilde{x}_i, \tilde{x}_j) = \alpha \rho(\tilde{x}_i, \tilde{x}_k)$$




# t-SNE. Step 1

**Gaussian Distribution Around Data Point**



# t-SNE. Step 2

## Normal vs Cauchy (Students-T) Distribution



## t-SNE. Step 3

$$\sum_{i=1}^{\ell} \sum_{j \neq i} p(x_j | x_i) \log \frac{p(x_j | x_i)}{q(\tilde{x}_j | \tilde{x}_i)} \rightarrow \min_{\tilde{x}_1, \dots, \tilde{x}_\ell}$$