

Al Community

8. Нейронные сети

План лекции



- 1. Перцептрон
- 2. Нейронные сети и функции активации
- 3. Метод обратного распространения ошибки

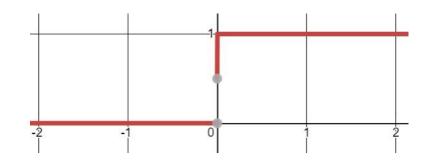
Перцептрон

Перцептрон



Перцептрон Розенблата - предшественник всех современных нейросетей, представляет собой линейную трансформацию со ступенчатой функцией активации.

$$f(x, w, b) = \begin{cases} 1, & \text{если } \sum_{i=1}^{n} w_i * x_i + b > 0 \\ 0, & \text{если } \sum_{i=1}^{n} w_i * x_i + b \le 0 \end{cases}$$



Линейный перцептрон

Ступенчатая функция активации

Перцептрон



Алгоритм обучения перцептрона:

- Для каждого примера из входных данных считаем активацию перцептрона на данном примере.
- 2. Если активация отличается от истинного значения, то обновляем веса, вычитая из них разность истинного и предсказанного значения
- 3. После того, как прошлись по всем примерам, возвращаемся к пункту 1 до тех пор, пока не достигнем критерия остановки (определенное количество циклов или определенный процент ошибок)

На прошлых лекциях



$$s=f(x;W)=Wx$$
 Линейная функция

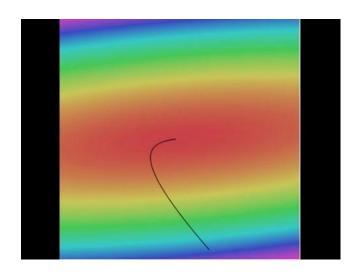
$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$
 Функция потерь SVM

$$L = rac{1}{N} \sum_{i=1}^N L_i + \lambda \sum_k W_k^2$$
 Ошибка данных + регуляризация

Оптимизация весов градиентным спуском







```
# Vanilla Gradient Descent

while True:
    weights_grad = evaluate_gradient(loss_fun, data, weights)
    weights += - step_size * weights_grad # perform parameter update
```

Градиентный спуск



$$rac{df(x)}{dx} = \lim_{h o 0} rac{f(x+h) - f(x)}{h}$$

Численно: медленный, неточный, прост для написания

Аналитически: быстро, точно, необходима проверка

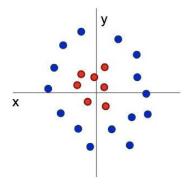
На практике для подсчета градиента выводят аналитическую формулу, а затем проверяют численными методами

Проблемы линейного классификатора





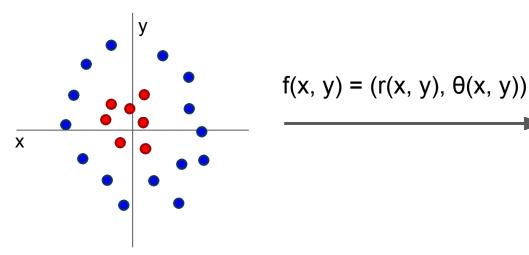
Линейные классификаторы учат один шаблон для каждого класса



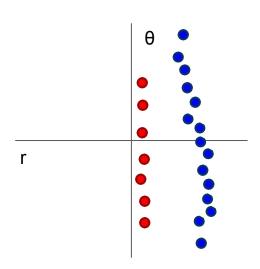
Линия разделения является одной прямой

Преобразование пространства





Нельзя разделить синие и красные точки одной прямой



После применения некой трансформации мы получаем линейно разделимые примеры



Линейная функция

$$f = Wx$$

$$x \in \mathbb{R}^D, W \in \mathbb{R}^{C \times D}$$



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть

$$f = W_2 \max(0, W_1 x)$$

$$x \in \mathbb{R}^D, W_1 \in \mathbb{R}^{H \times D}, W_2 \in \mathbb{R}^{C \times H}$$



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть

$$f = W_2 \max(0, W_1 x)$$

$$x \in \mathbb{R}^D, W_1 \in \mathbb{R}^{H \times D}, W_2 \in \mathbb{R}^{C \times H}$$

"Нейронная сеть" очень широкий термин; представленное лучше называть "полносвязной сетью" или "многослойным перцептроном" (MLP)



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть $f=W_2\max(0,W_1x)$

$$f = W_2 \max(0, W_1 x)$$

или трехслойная
$$f=W_3\max(0,W_2\max(0,W_1x))$$

$$x \in \mathbb{R}^D, W_1 \in \mathbb{R}^{H_1 \times D}, W_2 \in \mathbb{R}^{H_2 \times H_1}, W_3 \in \mathbb{R}^{C \times H_2}$$



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть $f=W_2\max(0,W_1x)$

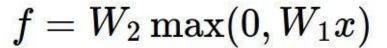
$$f = W_2 \max(0, W_1 x)$$

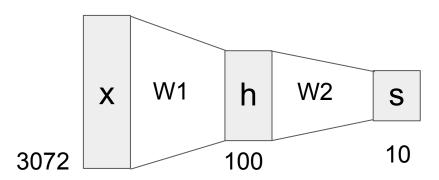
или трехслойная
$$f=W_3\max(0,W_2\max(0,W_1x))$$

$$x \in \mathbb{R}^D, W_1 \in \mathbb{R}^{H_1 \times D}, W_2 \in \mathbb{R}^{H_2 \times H_1}, W_3 \in \mathbb{R}^{C \times H_2}$$

Двухслойная нейронная сеть



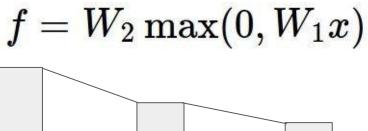


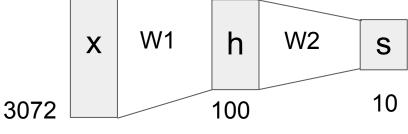


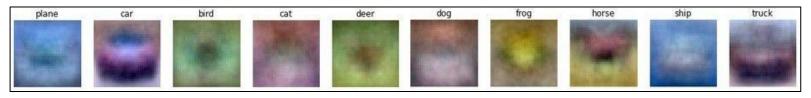
$$x \in \mathbb{R}^D, W_1 \in \mathbb{R}^{H \times D}, W_2 \in \mathbb{R}^{C \times H}$$

Двухслойная нейронная сеть









Обучаются 100 шаблонов вместо 10

Шаблоны используются всеми классами



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть
$$f=W_2\max(0,W_1x)$$

Функция max(0, z) называется функцией активации

Q: Что будет, если мы уберём её из нейронной сети?

$$f = W_2 W_1 x$$



Линейная функция

$$f = Wx$$

Двухслойная нейронная сеть

$$f=W_2 \overline{\max(0,W_1x)}$$

Функция max(0, z) называется функцией активации

Q: Что будет, если мы уберём её из нейронной сети?

$$f = W_2 W_1 x \qquad W_3 = W_2 W_1 \in \mathbb{R}^{C \times H}, f = W_3 x$$

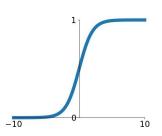
А: двухслойная сеть схлопнется в однослойную

Функции активации



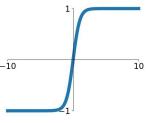
Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



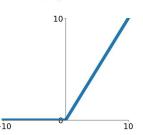
tanh

tanh(x)



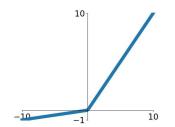
ReLU

 $\max(0, x)$



Leaky ReLU

 $\max(0.1x, x)$

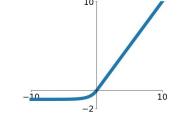


Maxout

 $\max(w_1^T x + b_1, w_2^T x + b_2)$

ELU

$$\begin{cases} x & x \ge 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

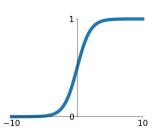


Функции активации



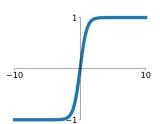
Sigmoid

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



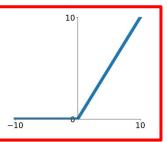
tanh

tanh(x)



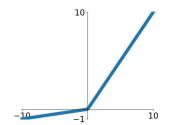
ReLU

 $\max(0, x)$



Leaky ReLU

 $\max(0.1x, x)$

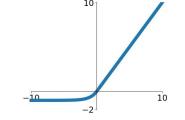


Maxout

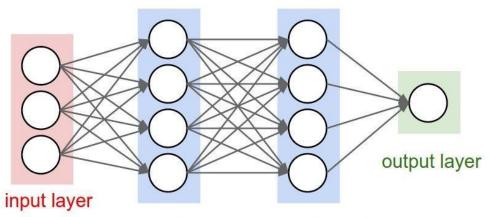
$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \ge 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$







hidden layer 1 hidden layer 2

```
# forward-pass of a 3-layer neural network:

f = lambda x: 1.0/(1.0 + np.exp(-x)) # activation function (use sigmoid)

x = np.random.randn(3, 1) # random input vector of three numbers (3x1)

h1 = f(np.dot(W1, x) + b1) # calculate first hidden layer activations (4x1)

h2 = f(np.dot(W2, h1) + b2) # calculate second hidden layer activations (4x1)

out = np.dot(W3, h2) + b3 # output neuron (1x1)
```



```
import numpy as np
    from numpy random import randn
 3
    N, D_{in}, H, D_{out} = 64, 1000, 100, 10
    x, y = randn(N, D in), randn(N, D out)
    w1, w2 = randn(D_in, H), randn(H, D_out)
    for t in range(2000):
 8
      h = 1 / (1 + np.exp(-x.dot(w1)))
 9
10
      y pred = h.dot(w2)
11
      loss = np.square(y_pred - y).sum()
      print(t, loss)
12
13
      grad y pred = 2.0 * (y pred - y)
14
      grad_w2 = h.T.dot(grad_y_pred)
15
      grad_h = grad_y_pred.dot(w2.T)
16
17
      grad w1 = x.T.dot(grad h * h * (1 - h))
18
      w1 -= 1e-4 * qrad w1
19
20
      w2 -= 1e-4 * grad w2
```



```
import numpy as np
    from numpy random import randn
    N, D_in, H, D_out = 64, 1000, 100, 10
    x, y = randn(N, D_in), randn(N, D_out)
    w1, w2 = randn(D_in, H), randn(H, D_out)
    for t in range(2000):
 8
      h = 1 / (1 + np.exp(-x.dot(w1)))
 9
10
      y pred = h.dot(w2)
11
      loss = np.square(y_pred - y).sum()
      print(t, loss)
12
13
      grad y pred = 2.0 * (y pred - y)
14
      grad_w2 = h.T.dot(grad_y_pred)
15
      grad_h = grad_y_pred.dot(w2.T)
16
17
      grad w1 = x.T.dot(grad h * h * (1 - h))
18
19
      w1 -= 1e-4 * qrad w1
20
      w2 -= 1e-4 * grad w2
```

Определяем параметры сети



```
import numpy as np
    from numpy random import randn
    N, D_{in}, H, D_{out} = 64, 1000, 100, 10
    x, y = randn(N, D in), randn(N, D out)
    w1, w2 = randn(D_in, H), randn(H, D_out)
    for t in range(2000):
 8
 9
      h = 1 / (1 + np.exp(-x.dot(w1)))
10
      y pred = h.dot(w2)
11
      loss = np.square(y_pred - y).sum()
      print(t, loss)
12
13
      grad y pred = 2.0 * (y pred - y)
14
      grad_w2 = h.T.dot(grad_y_pred)
15
      grad_h = grad_y_pred.dot(w2.T)
16
17
      grad w1 = x.T.dot(grad h * h * (1 - h))
18
19
      w1 -= 1e-4 * qrad w1
20
      w2 -= 1e-4 * grad w2
```

Определяем параметры сети

Определяем взаимосвязь параметров



```
import numpy as np
    from numpy random import randn
    N, D_{in}, H, D_{out} = 64, 1000, 100, 10
    x, y = randn(N, D in), randn(N, D out)
    w1, w2 = randn(D_in, H), randn(H, D_out)
    for t in range(2000):
      h = 1 / (1 + np.exp(-x.dot(w1)))
10
      y pred = h.dot(w2)
      loss = np.square(y_pred - y).sum()
      print(t, loss)
12
13
14
      grad y pred = 2.0 * (y pred - y)
      grad_w2 = h.T.dot(grad_y_pred)
15
      grad_h = grad_y_pred.dot(w2.T)
16
17
      grad w1 = x.T.dot(grad h * h * (1 - h))
18
19
      w1 -= 1e-4 * qrad w1
20
      w2 -= 1e-4 * grad w2
```

Определяем параметры сети

Определяем взаимосвязь параметров

Подсчёт градиентов аналитически



```
import numpy as np
    from numpy random import randn
    N, D_{in}, H, D_{out} = 64, 1000, 100, 10
    x, y = randn(N, D in), randn(N, D out)
    w1, w2 = randn(D_in, H), randn(H, D_out)
    for t in range(2000):
      h = 1 / (1 + np.exp(-x.dot(w1)))
 9
10
      y pred = h.dot(w2)
      loss = np.square(y_pred - y).sum()
12
      print(t, loss)
13
      grad y pred = 2.0 * (y pred - y)
14
      grad_w2 = h.T.dot(grad_y_pred)
15
      grad_h = grad_y_pred.dot(w2.T)
16
17
      grad w1 = x.T.dot(grad h * h * (1 - h))
18
19
      w1 -= 1e-4 * qrad w1
20
      w2 -= 1e-4 * grad w2
```

Определяем параметры сети

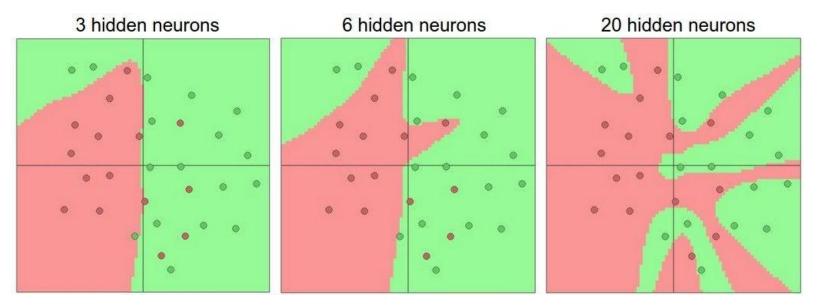
Определяем взаимосвязь параметров

Подсчёт градиентов аналитически

Градиентный спуск

Влияние количества нейронов и слоев

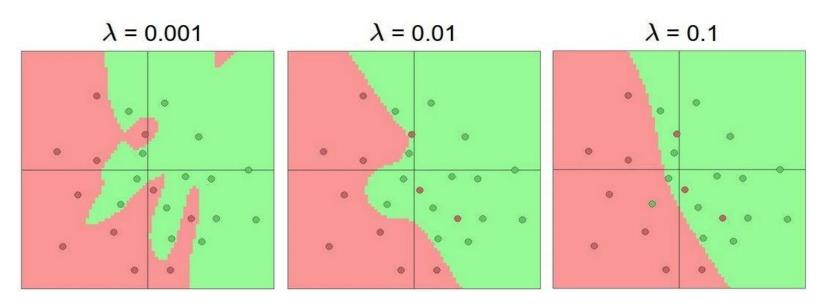




Больше слоев и нейронов - выше способность модели к аппроксимации данных. Но также и выше шанс переобучения.

Регуляризация





Для нейронных сетей также можно использовать регуляризацию, чтобы ограничить переобучение.

(Веб-демо ConvNetJS: http://cs.stanford.edu/people/karpathy/convnetjs/demo/classify2d.html)

Подсчёт градиентов



$$s = f(x; W_1, W_2) = W_2 \max(0, W_1 x)$$
 Нелинейная функция $L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$ Функция ошибки SVM

$$R(W) = \sum_k W_k^2$$
 Регуляризация

$$L = rac{1}{N} \sum_{i=1}^N L_i + \lambda R(W_1) + \lambda R(W_2)$$
 Итоговая ошибка

Если можем подсчитать

$$\dfrac{\partial L}{\partial W_1}, \dfrac{\partial L}{\partial W_2}$$
 сможем обучить $\mathbf{W_1}$ и $\mathbf{W_2}$

Подсчёт градиентов на листочке



$$s = f(x; W) = Wx$$

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

$$= \sum_{j \neq y_i} \max(0, W_{j,:} \cdot x + W_{y_i,:} \cdot x + 1)$$

$$L = \frac{1}{N} \sum_{i=1}^{N} L_i + \lambda \sum_{i=1}^{N} W_k^2$$

Проблемы такого подхода:

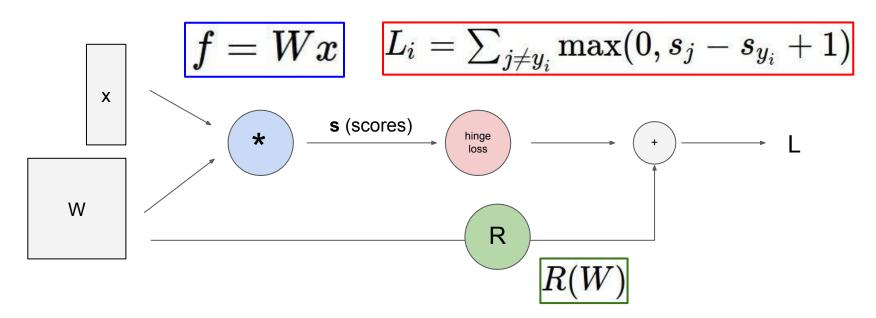
- 1. Крайне трудоемко
- 2. Не универсально (требует подсчетов для каждой модели
- 3. Практически невозможно для больших и сложных моделей

$$= \frac{1}{N} \sum_{i=1}^{N} \sum_{j \neq y_i} \max(0, W_{j,:} \cdot x + W_{y_i,:} \cdot x + 1) + \lambda \sum_{k} W_k^2$$

$$\nabla_{W} L = \nabla_{W} \left(\frac{1}{N} \sum_{i=1}^{N} \sum_{j \neq y_{i}} \max(0, W_{j,:} \cdot x + W_{y_{i},:} \cdot x + 1) + \lambda \sum_{k} W_{k}^{2} \right)$$

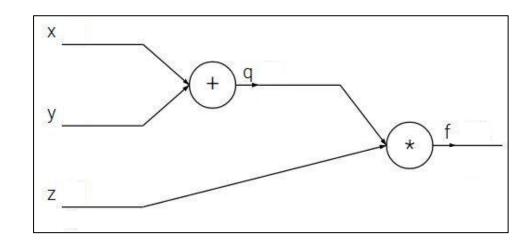


Backpropagation (Метод обратного распространения ошибки) основан на представлении нейронной сети в виде вычислительного графа



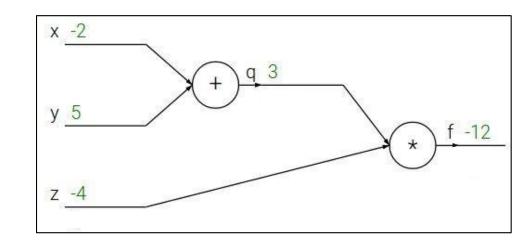
$$f(x,y,z) = (x+y)z$$

$$f(x,y,z)=(x+y)z$$



$$f(x, y, z) = (x + y)z$$

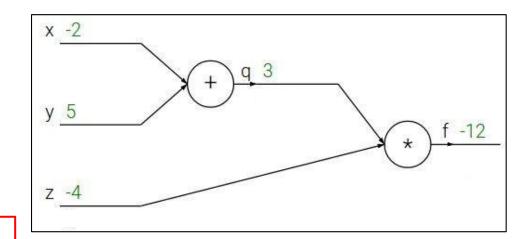
e.g. x = -2, y = 5, z = -4



$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1,$$

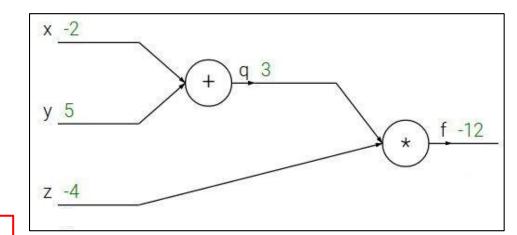


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \hspace{1cm} rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$

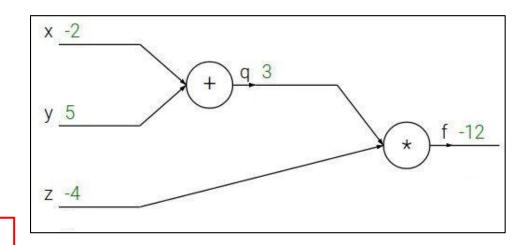


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

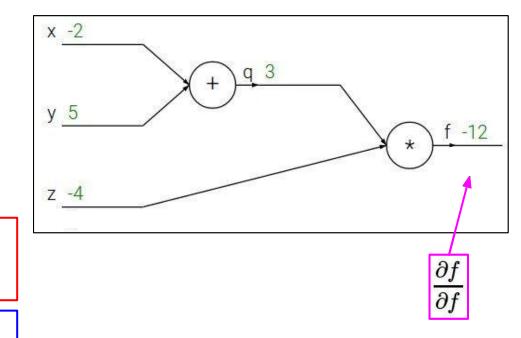


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \qquad \quad rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$

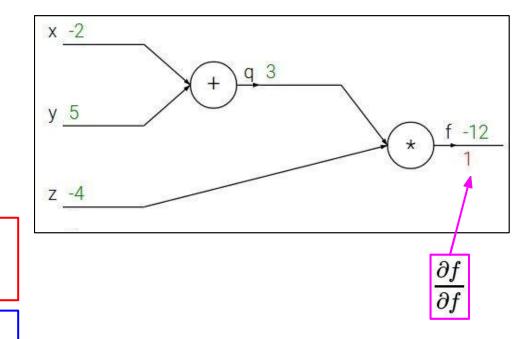


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

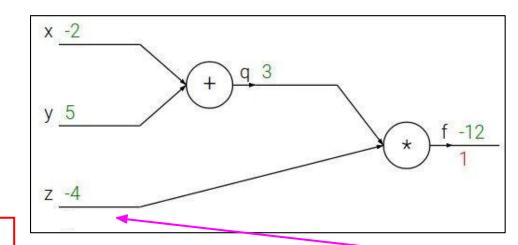


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$



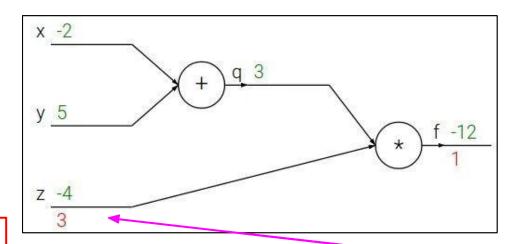
$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \hspace{1cm} rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$

Нужно $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



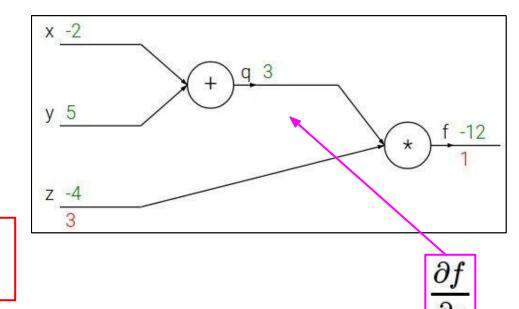
 $\frac{\partial f}{\partial z}$

$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

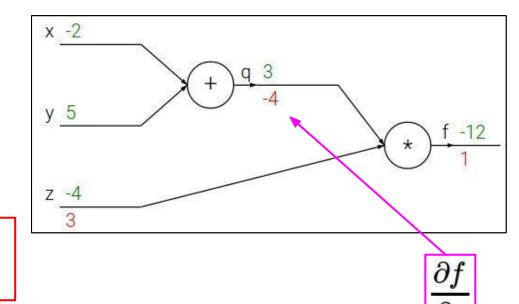


$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \hspace{1cm} rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$



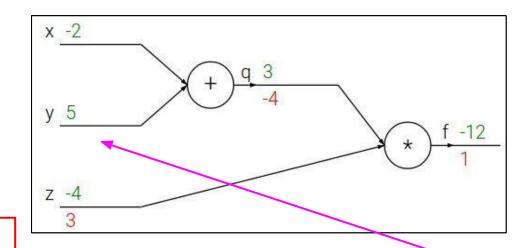
$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz \hspace{1cm} rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$

Нужно $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



Правило цепи:

$$rac{\partial f}{\partial y} = rac{\partial f}{\partial q} rac{\partial q}{\partial y}$$
 Восходящий Локальн

Локальный градиент градиент

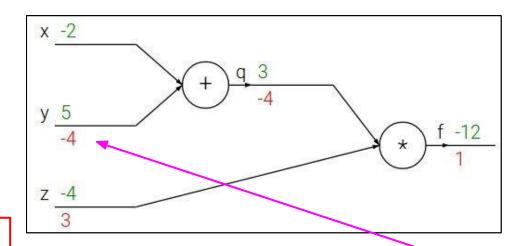
$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y$$
 $\frac{\partial q}{\partial x}=1, \frac{\partial q}{\partial y}=1$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Нужно $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



Правило цепи:

$$rac{\partial f}{\partial y} = rac{\partial f}{\partial q} rac{\partial q}{\partial y}$$
Восходящий Локальный градиент

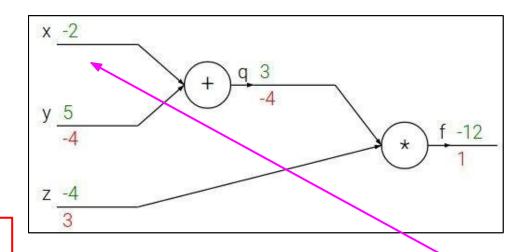
$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y$$
 $\frac{\partial q}{\partial x}=1, \frac{\partial q}{\partial y}=1$

$$f=qz \hspace{1cm} rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$$

Нужно $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



Правило цепи:

$$rac{\partial f}{\partial x} = rac{\partial f}{\partial q} rac{\partial q}{\partial x}$$
 Восходящий Локаль

Восходящий Локальный градиент

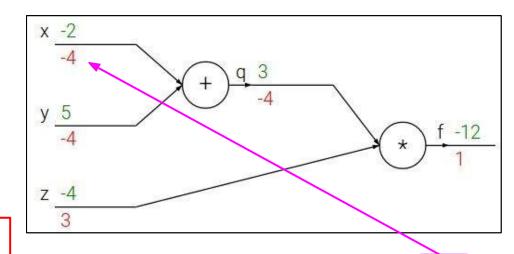
$$f(x, y, z) = (x + y)z$$

e.g. x = -2, y = 5, z = -4

$$q=x+y \qquad rac{\partial q}{\partial x}=1, rac{\partial q}{\partial y}=1$$

$$f=qz$$
 $rac{\partial f}{\partial q}=z, rac{\partial f}{\partial z}=q$

Нужно $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$



Правило цепи:

$$rac{\partial f}{\partial x} = rac{\partial f}{\partial q} rac{\partial q}{\partial x}$$
 Восходящий Локали

градиент

й Локальный градиент

